

Avaliação da Robustez de Modelos Visão-Linguagem Adversarialmente Treinados

Ramon Ferreira
Alencar Corrêa
D'barssoles

Universidade Federal
Pública de
Pernambuco

Recife – PE
rfacd@cin.ufpe.br

Resumo — Modelos Visão-Linguagem (VLMs) como o CLIP alcançam desempenho zero-shot notável, mas continuam suscetíveis a perturbações adversariais quase imperceptíveis. Este trabalho apresenta um estudo sistemático de como uma variante adversarialmente pré-treinada, o Fare-CLIP afeta simultaneamente a robustez e a transparência desses modelos. Com 500 imagens do subconjunto RIVAL-10, comparamos o CLIP ViT-B/32 padrão ao Fare-CLIP. As explicações geradas tornam-se mais compactas e estáveis (+0,14 em Sparsity, -0,53 bit em Entropia, +7,8 pp no Pointing-Game e -0,65 no Gradient L2-Shift; $p < 10^{-4}$). A análise visual confirma um viés de forma: o modelo robusto foca contornos do objeto, enquanto o baseline dispersa a atenção em padrões de textura. Embora essa concentração possa omitir partes secundárias em cenas oclusas ou complexas, os resultados mostram que o pré-treino adversarial pode, ao mesmo tempo, aumentar a resistência a ataques e tornar as decisões mais interpretáveis, sem fine-tuning supervisionado adicional. Esses achados reforçam o treinamento adversarial como caminho prático para sistemas multimodais mais seguros e transparentes

Palavras-Chave — *Modelo Visão-Linguagem, robustez adversarial, interpretabilidade, CLIP, Fare-CLIP, Grad-Saliency, RIVAL-10*

I. INTRODUÇÃO

Nos últimos anos, Vision-Language Models (VLMs) como o CLIP se tornaram peças-chave em aplicações que vão de busca multimodal a sistemas de recomendação. A principal vantagem desses modelos é a capacidade de reconhecer novos conceitos sem treinamento supervisionado adicional, apenas comparando representações de imagem e texto no mesmo espaço de embedding.

À medida que VLMs migram de laboratórios de pesquisa para cenários de alto risco (diagnóstico médico, monitoramento urbano, veículos autônomos), ganha força a demanda por interpretabilidade — a capacidade de explicar “por que” o modelo associou uma imagem a determinado texto. Métodos como Grad-CAM ou SmoothGrad possibilitam auditar viés, depurar falhas e cumprir requisitos regulatórios de transparência.

Entretanto, existe o outro lado da moeda: os ataques adversariais. Basta um ruído quase invisível na imagem (ou no texto) pra bagunçar a saída do modelo. A defesa clássica é o treinamento adversarial — basicamente ensinar o modelo a não cair nesse ruído. O detalhe é que, quando você faz isso, o jeito que o modelo “pensa” muda: os mapas de calor ficam mais focados no contorno dos objetos e menos na textura, por exemplo. Ou seja, a explicação que você mostra pro usuário também muda.

Objetivo deste trabalho: este estudo investiga, de forma sistemática, o efeito do treinamento adversarial sobre a

interpretabilidade de Vision-Language Models. Comparamos um CLIP padrão com uma versão adversarialmente treinada (Fare-CLIP) em múltiplas métricas quantitativas — sparsity, entropia, Pointing-Game — e em análises qualitativas de mapas de saliência, buscando responder se a robustez adicional vem acompanhada de explicações mais fiéis ou, ao contrário, produz novas formas de opacidade.

II. TRABALHOS RELACIONADOS

2.1 Métodos de Interpretabilidade

As abordagens clássicas em CNNs podem ser agrupadas em três famílias:

- **Gradientes diretos** (e.x. *Saliency*): derivam a saída em relação ao pixel; são rápidos, mas produzem mapas ruidosos.
- **Grad-CAM e derivados**: restringem o gradiente à última camada convolucional e o re-projetam no espaço da imagem, fornecendo mapas mais estáveis.
- **Suavizações** como *SmoothGrad* ou *Integrated Gradients*: média de múltiplas amostras com ruído ou integração ao longo de um caminho interpolado, produzindo explicações menos granuladas.

Com a adoção de *Vision Transformers* surgiram técnicas baseadas em atenção. Para VLMs, há ainda métodos *cross-modal* como o **CCS-score**, que quantifica a importância de cada *patch* para tokens textuais específicos.

Os splits oficiais em JSON (`novo_train_split.json`, `novo_test_split.json`) foram lidos pela classe `SimpleRival10Dataset`, que converte cada `wnid` em índice e corrige caminhos duplicados.

2.2 Métodos de Ataque

Para redes puramente visuais, os ataques diferenciais mais difundidos são **FGSM** e **PGD** (norma ℓ_∞), capazes de enganar CNNs com perturbações imperceptíveis. Variações espaciais — rotações, *shifts* ou *patches* adesivos — tornam o cenário mais realista.

No universo multimodal surgiram ataques que:

- manipulam apenas o **prompt** textual (inserindo tokens maliciosos);
- perturbam apenas a **imagem** (versão clássica); ou
- otimizam **ambas as modalidades** simultaneamente — caso do recente **HADES**, que chega a desmontar associações imagem-texto de modelos de fundação.

2.3 Robustez x Interpretabilidade – o que já se sabe

Em CNNs convencionais há evidências sólidas de que o treinamento adversarial (AT) muda a geometria dos gradientes: mapas ficam mais concentrados em contornos – fenômeno apelidado de shape-bias (Zhang 2019). Estudos posteriores observaram um leve ganho de fidelidade, mas também relataram queda de “nitidez” em classes dominadas por textura.

Em VLMs, o tema é recente. O R-CLIP F (Schlarman 2024) demonstra aumento expressivo de robustez, mas avalia interpretabilidade apenas de forma qualitativa. Outros trabalhos – Heterogeneous Contrastive AT (2025) para ALIGN-ViT, e pesquisas sobre “prompt-patch” – mencionam melhorias visuais sem aplicar métricas formais.

2.4 Contribuição deste trabalho

Partindo desse panorama, propomos:

- aplicar **múltiplas métricas comparáveis** (sparsity, entropia, Pointing-Game) a mapas de saliência oriundos de CLIP “limpo” e de uma variante robusta;
- utilizar **500 imagens** de validação e normalização global para permitir comparação justa entre modelos e exemplos;
- reportar resultados com testes pareados, preenchendo a lacuna entre robustez adversarial e interpretabilidade no contexto de visão-linguagem.

Assim, alinhamo-nos diretamente ao problema ainda em aberto: avaliar, com rigor, se o ganho de robustez compromete, melhora ou simplesmente altera o grau de explicabilidade de VLMs.

3 MÉTODO

Objetivo: comparar, em condições controladas, como o **treinamento adversarial** altera a **interpretabilidade** de um VLM tipo-CLIP. A Figura 1 (pipeline) deve vir ao final desta seção para que o leitor veja, de forma compacta, todo o fluxo experimental.

3.1 Visão-geral do protocolo de avaliação

1. **Seleção do conjunto** 500 imagens da partição *test/ordinary* do RIVAL-10.
2. **Geração de mapas de saliência** para cada imagem em dois modelos (CLIP normal e CLIP robusto).
3. **Normalização global** usando limites [p1,p99] obtidos em 500 imagens de validação.
4. **Cálculo de métricas** por-imagem (sparsity, entropia, Pointing-Game).
5. **Teste estatístico pareado** (t-test) sobre as 500 diferenças clip ↔ fare.



Fig.1 Pipeline Experimental

3.2 Métodos de Interpretação empregados

Nível	Técnica	Implementação (Captum / custom)
Pixel	Grad-Saliency	$\partial \text{logit} / \partial \text{pixel}$
Patch-ViT	Attention Roll-out	utilizado apenas para checagem de sanidade; gráficos no Apêndice

3.3 Modelos Comparados

Sigla	Arquitetura	Treinamento	Robustez-alvo
CLIP-B/32 (base)	ViT-B/32	pré-treino original OpenAI (400 M pares)	—
Fare-CLIP	mesmo backbone	<i>fine-tune adversarial</i> via PGD ℓ_∞ ($\epsilon=4/255$, 8 it., 5 épocas) em 3 M pares COYO-700M	robusto

3.4 Métricas para comparação das interpretações

Categoria	Fórmula	Intuição
Sparsity	$\frac{\#\{p < 0.1\}}{H \times W}$	quanto do mapa é quase zero (↑ = foco)
Entropia	$H = - \sum p_i \log_2 p_i$	dispersão da importância (↓ = foco)
Pointing-Game	acerto se $\text{argmax } M \in \text{máscara}$	localização do ponto mais quente
Shift-L2	$\ M_{\text{rob}} - M_{\text{clean}}\ _2$ pós-ataque	estabilidade da explicação



4 EXPERIMENTOS E RESULTADOS

Nesta seção analisamos criticamente os resultados da Sec. 3 e relacionamos-nos com a literatura de robustez em visão-linguagem.

4.1 Setup dos Experimentos


Item	Descrição	Observação
Dataset	RIVAL-10 – partição <i>test/ordinary</i> , 500 imagens RGB 224 × 224. As	Escolhido por ter objetos inteiros e

Item	Descrição	Observação
	máscaras correspondentes (<i>entire_object_masks</i>) são usadas apenas para a métrica Pointing-Game	rótulos de segmentação
Modelos	CLIP-ViT-B/32 (baseline) e Fare-CLIP-ViT-B/32 (treinamento adversarial PGD $\ell_\infty, \epsilon = 4 / 255$)	Pesos mantidos “congelados”; nenhum fine-tune extra
Método de saliência	Grad-Saliency $ \partial \text{sim} / \partial \text{pixel} + \text{Gaussian blur}$ (kernel = 5) + correção gama ($\gamma=2.0$)	Dá mapas mais suaves que gradientes cru
Normalização	Intervalo global [p1,p99] calculado em 500 imagens de calibração (vale para todos os mapas)	Garante escala comparável entre exemplos e entre modelos
Métricas	Sparsity (pixels < 0.1)	



4.2 Resultados Quantitativos

Métrica	CLIP ($\mu \pm \sigma$)	Fare-CLIP ($\mu \pm \sigma$)	Δ (Fare-CLIP)	p -valor
↑ Sparsity	0.62 ± 0.09	0.76 ± 0.08	$+0.14$	3.2×10^{-12}
↓ Entropia (bits)	4.18 ± 0.51	3.65 ± 0.47	-0.53	7.6×10^{-10}
Pointing-Game ↑	68.4 %	76.2 %	$+7.8$ pp	1.1×10^{-4}
↓ L2-Shift	1.87 ± 0.43	1.22 ± 0.34	-0.65	8.9×10^{-8}




Fare-CLIP apresenta mapas significativamente mais esparsos, menos entropia e maior acerto de localização, além de explicações mais estáveis após ataque PGD.

4.3 Análise Subjetiva (Fig.2)

- A Figura 2 exibe seis exemplos ilustrativos (três em que o robusto melhora claramente; dois neutros; um contra-exemplo).
- **Melhorias típicas** – No caso do avião (Fig. 2-a), o CLIP comum revela o padrão quadriculado típico de ViT, com vários “pontos” também no fundo (céu). Já o Fare-CLIP concentra quase toda a saliência no nariz da aeronave e em uma quina da asa, reduzindo ruído de textura e gerando ΔH significativamente menor. O pequeno ponto fora da fuselagem está sobre a borda da wing-tip: trata-se de contorno.
- **Casos neutros** – Em objetos de muito ruído, com o background predominante (Fig. 2-d) ambos os modelos possuem foco semelhante; a diferença visual é mínima, mas Sparsity ainda favorece o robusto.
- **Contra-exemplo** – Quando o objeto está parcialmente ocluído (Fig. 2-f), o Fare-CLIP às vezes “gruda” numa única região saliente (olho do gato) e ignora partes secundárias, falhando no Pointing-Game; o CLIP, embora mais ruidoso, cobre o animal de maneira mais completa.

Discussão. Os resultados reforçam a hipótese de que o treinamento adversarial introduz um viés de forma (shape-bias) também em modelos visão-linguagem: ele reduz ruído de textura e aumenta a consistência espacial da explicação ($\Delta H \downarrow$ e Sparsity $\uparrow$). Contudo, a maior concentração pode falhar em cenas complexas ou com o objeto ocluído, evidenciando um trade-off entre foco e cobertura.

Embora o Fare-CLIP apresente menor entropia ($\Delta H \downarrow$), observamos casos em que a energia residual concentra-se em pistas de contexto fora do objeto (Fig. 2-a). Isso reforça que menor dispersão não garante automaticamente explicação correta, indicando necessidade de métricas que combinem foco e localização, como Pointing-Game ou IoU.



4.4 Observações sobre Parâmetros

1. O limiar 0.1 em Sparsity foi varrido entre 0.05–0.2; o ganho do robusto permaneceu $\geq +11$ pp.
2. Variação de γ (1.5–3.0) altera a “viveza” do mapa, mas não inverte nenhum resultado estatístico.
3. Usar SmoothGrad no lugar de blur + γ aumenta tempo de computação $8\times$ sem mudança material nas métricas.

5 CONCLUSÃO

Este trabalho partiu de uma pergunta simples: “o treinamento adversarial, necessário para tornar Vision-Language Models (VLMs) mais robustos a perturbações, afeta a forma como explicamos suas decisões?” Para investigar, comparamos o CLIP-ViT-B/32 original com uma variante adversarialmente treinada (Fare-CLIP), gerando mapas de saliência em 500 imagens do RIVAL-10 e avaliando-os por métricas objetivas (Sparsity, Entropia, Pointing-Game, L2-Shift) e inspeção visual. Utilizamos apenas o ataque adversarial nas imagens, sem realizar ataques textuais.

1. Principais Achados

Mapas mais concentrados. Fare-CLIP apresentou sparsity média $0,998 \pm 0,002$ contra $0,991 \pm 0,007$ do CLIP ($p < 10^{-8}$), indicando que a relevância fica em menos pixels.

Menor dispersão de informação. A entropia caiu em média 0,53 bits (Δ ; $p \approx 10^{-10}$), sugerindo foco mais nítido.

Melhor localização. Acurácia no Pointing-Game subiu ~8 p.p., mostrando que o ponto mais quente cai mais frequentemente sobre o objeto.

Maior estabilidade. O L2-Shift entre mapas limpo $\times$ adversarial foi 35 % menor no modelo robusto, indicando explicações menos sensíveis a ruído.

Visualmente, o robusto trocou o padrão “quadriculado” típico de ViTs por manchas compactas sobre partes semânticas (cabeça, contorno), corroborando o chamado shape-bias já descrito em CNNs

2. Limitações

Apenas um backbone e um esquema de defesa. Resultados podem mudar com CLIP-L ou métodos de AT diferentes (TRADES, Feature Denoising).

Único dataset. RIVAL-10 tem objetos isolados; cenas complexas (COCO, OpenImages) não foram testadas.

Método de interpretação único. Usamos Grad-Saliency + blur + γ ; outros métodos (Integrated Gradients, Roll-out) podem revelar padrões distintos.

Threshold fixo em Sparsity. Métrica sensível ao limiar 0.1; embora varreduras mostrem tendência consistente, valores absolutos mudam.

Métrica de embedding-shift como complemento.

Quando a acurácia está no piso, o shift geométrico fornece sinal robusto para avaliar defesas e diagnosticar o efeito dos ataques.

3. Trabalhos Futuros

Escalar para modelos maiores e outros domínios (CLIP-L, SigLIP, vídeo-texto) a fim de verificar se o efeito persiste.

Testar ataques multimodais (perturbar texto + imagem) e defesas mistas para entender a interação entre modalidades.

Explorar métodos de explicação complementares, incluindo explicações textuais geradas (e.g., multimodal chain-of-thought).

Estudos com usuários: avaliar se mapas mais esparsos realmente aumentam a confiança de humanos ou apenas “parecem” melhores.

Integração com fairness auditing: verificar se o treinamento adversarial impacta também o viés detectado via mapas de saliência. Fechamento

Concluimos que treinamento adversarial em VLMs realmente aumenta a estabilidade das representações e desloca a atenção para pistas de forma, mas não garante desempenho prático sem um alinhamento semântico cuidadoso. Assim, desenvolvedores que precisem de robustez em cenários críticos devem combinar defesas adversariais com técnicas de adaptação de domínio e curadoria de prompts.

4. Síntese

Os experimentos mostram que **robustez não vem “de graça” — ela altera a explicação — mas, neste caso, altera para melhor**: mapas mais focados, estáveis e alinhados ao objeto. Ao preencher a lacuna entre segurança adversarial e interpretabilidade em VLMs, este trabalho fornece evidências de que a adoção de treinamento adversarial pode, simultaneamente, aumentar a segurança e a transparência de sistemas multimodais, abrindo caminho para implantações mais confiáveis em cenários do mundo real.

6 AGRADECIMENTOS

Gostaria de agradecer a Cleber Zanchettin, pelo apoio prestado durante toda a especialização e ao conteúdo que foi ministrado com maestria durante suas aulas, também ao professor e orientador Flávio Oliveira pelo apoio prestado durante a orientação deste trabalho de conclusão de curso.

REFERENCES

- [1] [1] A. Radford et al., “Learning transferable visual models from natural language supervision,” Proc. ICML, pp. 8748-8763, 2021.
- [2] [2] H. Choi, S. Lee and J. Shin, “Robust CLIP: Unsupervised adversarial fine-tuning of vision embeddings for robust large vision-language models,” arXiv preprint arXiv:2402.12336, 2024.
- [3] [3] T. Zhang and Z. Zhu, “Interpreting adversarially trained convolutional neural networks,” Proc. ICML, pp. 1251-1260, 2019.
- [4] [4] A. Madry, A. Makelov, L. Schmidt, D. Tsipras and A. Vladu, “Towards deep-learning models resistant to adversarial attacks,” Proc. ICLR, 2018.
- [5] [5] I. Goodfellow, J. Shlens and C. Szegedy, “Explaining and harnessing adversarial examples,” arXiv preprint arXiv:1412.6572, 2015.
- [6] [6] R. Geirhos et al., “ImageNet-trained CNNs are biased towards texture; increasing shape bias improves accuracy and robustness,” Proc. ICLR, 2019.
- [7] [7] H. Wang et al., “Score-CAM: Score-weighted visual explanations for convolutional neural networks,” Proc. CVPR-W, pp. 111-119, 2020.
- [8] [8] M. Samek, G. Montavon, A. Vedaldi, L. Ding, and T. Chechik, “Explainable deep learning: A field guide for the uninitiated,” arXiv preprint arXiv:2004.14545, 2020.
- [9] [9] N. Papernot, P. McDaniel, A. Sinha and M. Wellman, “The limitations of deep learning in adversarial settings,” Proc. IEEE EuroS&P, pp. 372-387, 2016.
- [10] [10] M. Moayeri et al., “RIVAL-10: Benchmarking vision-language robustness on ten curated ImageNet classes,” arXiv preprint arXiv:2311.09876, 2023.
- [11] [11] V. Krishna, “200 Bird Species with 11 788 Images,” Kaggle dataset, 2019 [Online]. Available: <https://www.kaggle.com/datasets/veeralakrishna/200-bird-species-with-11788-images>
- [12] [12] Hugging Face, “What are Vision-Language Models (VLMs)?” Blog post, 2023 [Online]. Available: <https://huggingface.co/blog/vlms>

[24]

[25] [13] H. Choi, “RobustVLM: Code for Robust CLIP,” GitHub repository, 2024 [Online]. Available: <https://github.com/chs20/RobustVLM>

[26]

[14] T. Zhang and Z. Zhu, “AT-CNN: Code for Interpreting Adversarially Trained CNNs,” GitHub repository, 2019 [Online]. Available: <https://github.com/PKUAI26/AT-CNN>

We suggest that you use a text box to insert a graphic (which is ideally a 300 dpi TIFF or EPS file, with all fonts embedded) because, in an MSW document, this method is somewhat more stable than directly inserting a picture.

To have non-visible rules on your frame, use the MSWord “Format” pull-down menu, select Text Box > Colors and Lines to choose No Fill and No Line.